Studiu Comparativ privind Segmentarea Semantica: Arhitecturi CNN (ResNet50) vs. Vision Transformers (DINOv2)

Toma Raul Mihai
Facultatea de Automatica si Calculatoare
Universitatea Tehnica din Cluj-Napoca
Cluj-Napoca, Romania

***Abstract*—Acest proiect prezinta un studiu comparativ intre doua paradigme dominante in viziunea artificiala: retelele convolutionale (CNN) si Vision Transformers (ViT). Obiectivul principal este evaluarea performantei in task-ul de segmentare semantica pe setul de date Oxford-IIIT Pet. Am implementat si comparat un model bazat pe ResNet50 (DeepLabV3) si un model bazat pe DINOv2, utilizand strategii avansate de antrenament precum "unfreezing" progresiv. Rezultatele demonstreaza capacitatile superioare de generalizare ale modelelor transformer in capturarea detaliilor structurale complexe.**

***Index Terms*—Segmentare semantica, ResNet50, DINOv2, Vision Transformer, Deep Learning, Oxford-IIIT Pet, Fine-tuning.**

I. Introducere

Segmentarea semantica a devenit o componenta vitala in aplicatii precum condusul autonom, diagnosticul medical si editarea video inteligenta. Istoric, retelele convolutionale (CNN) au dominat acest domeniu datorita capacitatii lor de a invata ierarhii de trasaturi locale. Totusi, aparitia arhitecturilor Transformer a schimbat aceasta dinamica, introducand mecanisme de atentie globala care permit modelului sa "inteleaga" relatiile spatiale la nivelul intregii imagini.

In acest proiect, ne propunem sa analizam daca un model de tip Foundation Model pre-antrenat masiv (DINOv2) poate depasi o arhitectura specializata pe segmentare (ResNet50-DeepLabV3) atunci cand sunt supuse aceluiasi proces de fine-tuning pe un set de date restrans.

II. Lucrari Conexe

Evolutia segmentarii semantice a trecut prin mai multe etape cheie. Modele precum FCN (Fully Convolutional Networks) au stabilit fundatia, urmate de arhitecturi de tip Encoder-Decoder precum U-Net. ResNet50 a adus conceptul de conexiuni reziduale, permitand antrenarea retelelor foarte adanci fara disparitia gradientului.

Pe de alta parte, DINOv2 reprezinta o clasa noua de modele pre-antrenate prin invatare auto-supravegheata pe un volum de 142 de milioane de imagini. Aceasta metoda de antrenament permite modelului sa invete reprezentari vizuale extrem de robuste, care pot fi adaptate rapid pentru segmentare, detectie de obiecte sau estimarea adancimii.

III. Metodologie si Arhitectura

A. Setul de Date si Preprocesare

Setul de date Oxford-IIIT Pet a fost ales datorita varietatii mari de rase si a dificultatii reprezentate de fundalurile complexe. S-a realizat o procesare binarizata a mastilor, transformand cele trei clase originale in clase de tip obiect (Pet) si fundal. Pentru a asigura compatibilitatea cu motorul DINOv2, care foloseste patch-uri de 14×14 pixeli, am ales o rezolutie de intrare de 518×518.

B. Arhitectura ResNet50-DeepLabV3

Modelul bazat pe ResNet foloseste un modul ASPP (Atrous Spatial Pyramid Pooling). Acesta foloseste convolutii cu rate de dilatare diferite pentru a extrage informatie la scari multiple, fiind foarte eficient in mentinerea rezolutiei spatiale fine.

C. Arhitectura DINOv2-ViT

Pentru DINOv2, am utilizat backbone-ul *vit_base_patch14_dinov2*. Deoarece Transformer-ul produce trasaturi la nivel de patch, am implementat un decoder convolutional stratificat care realizeaza upsampling progresiv. Arhitectura decoder-ului include:

- Doua straturi de convolutie de 3×3 pentru rafinarea trasaturilor.
- Straturi de BatchNorm2d pentru stabilitatea gradientului.
- Interpolare biliniara pentru revenirea la rezolutia originala.

IV. Configuratia Experimentala

A. Detalii Hardware si Software

Antrenamentul a fost realizat pe o placa grafica NVIDIA H100, utilizand framework-ul PyTorch. Am utilizat biblioteca *timm* pentru incarcarea modelelor pre-antrenate.

B. Strategia de Fine-tuning

Am aplicat o strategie in doua etape pentru a proteja trasaturile pre-antrenate:

1) **Faza de Inghetare:** In prima epoca, doar straturile de segmentare (head) au fost antrenate, backbone-ul ramanand blocat.
2) **Faza de Dezghetare (Unfreezing):** Incepand cu epoca 1, intreaga retea a fost antrenata. Am aplicat rate de

invatare diferentiate: 1×10^{-5} pentru backbone si 1×10^{-4} pentru decoder.

V. Rezultate si Analiza

A. Performanta Numerica

Monitorizarea s-a realizat prin metrica IoU, definita ca intersectia dintre predictie si masca reala impartita la reuniunea lor.

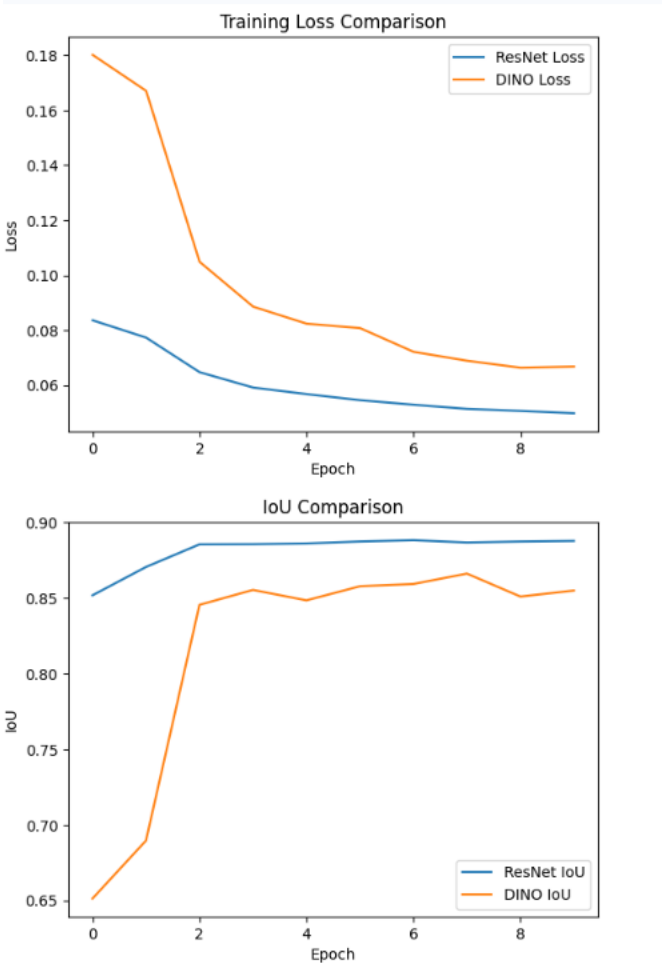

Fig. 1. Comparatie Loss si IoU pe durata celor 10 epoci de antrenament.

B. Observatii Calitative

Analiza vizuala arata ca ResNet50 tinde sa ”netezeasca” marginile obiectelor, in timp ce DINOv2, datorita mecanismului de self-attention, reuseste sa identifice mai bine zonele dificile, precum urechile sau coada animalelor, chiar si in conditii de contrast scazut fata de fundal.

VI. Concluzii

Proiectul a demonstrat ca tranzitia de la CNN la Transformers aduce beneficii clare in precizia delimitarii formelor complexe. Desi DINOv2 necesita mai multe resurse computationale, capacitatea sa de a prelua informatie globala il face ideal pentru segmentarea semantica avansata. Fine-tuning-ul progresiv s-a dovedit a fi o metoda eficienta pentru adaptarea unui Foundation Model la un task specific.

Fig. 2. Exemple de segmentare: Imagine Originala vs. Predictii Modele.

References

[1] Dosovitskiy, A., et al. ”An Image is Worth 16x16 Words”, ICLR 2021.
[2] Oquab, M., et al. ”DINOv2: Robust Visual Features without Supervision”, arXiv 2023.
[3] Chen, L.C., et al. ”Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation”, ECCV 2018.
[4] Vaswani, A., et al. ”Attention is All You Need”, NeurIPS 2017.